

TFG - 2. Preprocessament i anàlisi descriptiva de la base de dades

Joel Masdeu

2026-03-16

Lectura de les dades

```
library(readxl)
dades <- read_excel("C:/Users/joelm/Downloads/TFG/bbdd_psacard.xlsx")

dades$Price <- gsub(",", "", dades$Price)
dades$Price <- as.numeric(dades$Price)
dades$Date <- as.Date(dades$Date)
dades$Vintage <- as.factor(dades$Vintage)

# Etiquetem els dos nivells de Vintage:
dades$Vintage <- factor(dades$Vintage,
                        levels = c(0, 1),
                        labels = c("Moderna", "Vintage"))

library(dlookr)
dlookr::diagnose(dades) #comprovar que després de modificar les variables no tenim cap missing.
```

```
## # A tibble: 4 x 6
##   variables types      missing_count missing_percent unique_count unique_rate
##   <chr>      <chr>          <int>          <dbl>          <int>          <dbl>
## 1 ID_Card   character            0            0            20      0.000966
## 2 Date      Date                0            0           2715      0.131
## 3 Price     numeric             0            0           4808      0.232
## 4 Vintage   factor              0            0            2      0.0000966
```

```
str(dades)
```

```
## tibble [20,714 x 4] (S3: tbl_df/tbl/data.frame)
##  $ ID_Card: chr [1:20714] "vin1_charizard_holo_baseset_psa9" "vin1_charizard_holo_baseset_psa9" "vin1_
##  $ Date   : Date[1:20714], format: "2016-09-18" "2016-09-24" ...
##  $ Price  : num [1:20714] 164 152 118 148 112 ...
##  $ Vintage: Factor w/ 2 levels "Moderna","Vintage": 2 2 2 2 2 2 2 2 2 2 ...
```

Anàlisi exploratòria descriptiva de les dades (EDA)

Gràfics de les sèries temporals

```
summary(dades)
```


```
##      ID_Card      Date      Price      Vintage
## Length:20714    Min.   :2016-09-12    Min.   :    0.0 Moderna:10965
## Class :character 1st Qu.:2021-01-03    1st Qu.:  152.0 Vintage: 9749
## Mode  :character Median :2022-09-18    Median :  372.0
##                      Mean  :2022-05-20    Mean   :  596.4
##                      3rd Qu.:2024-04-15    3rd Qu.:  800.0
##                      Max.   :2026-03-02    Max.   :25000.0
```

```
library(ggplot2)
library(dplyr)

# Gràfic cartes vintage
grafic_vintage <- dades %>%
  filter(Vintage == "Vintage") %>%
  ggplot(aes(x = Date, y = Price)) +
  geom_point(alpha = 0.5, size = 1.5, color = "#00BFC4") +
  geom_line(alpha = 0.7, color = "#00BFC4") +
  facet_wrap(~ ID_Card, scales = "free_y", ncol = 2) +
  scale_x_date(date_labels = "%Y", date_breaks = "1 year") +
  theme_minimal() +
  labs(
    title = "Evolució del preu - Cartes Vintage (1999-2000)",
    x = "Data de venda",
    y = "Preu (USD)"
  ) +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))

print(grafic_vintage)
```


Evolució del preu - Cartes Vintage (1999-2000)



```
# Gràfic cartes modernes
grafic_modernes <- dades %>%
  filter(Vintage == "Moderna") %>%
  ggplot(aes(x = Date, y = Price)) +
  geom_point(alpha = 0.5, size = 1.5, color = "#F8766D") +
  geom_line(alpha = 0.7, color = "#F8766D") +
  facet_wrap(~ ID_Card, scales = "free_y", ncol = 2) +
  scale_x_date(date_labels = "%Y", date_breaks = "1 year") +
  theme_minimal() +
  labs(
    title = "Evolució del preu - Cartes Modernes (2017-2021)",
    x = "Data de transacció",
    y = "Preu (USD)"
  ) +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))

print(grafic_modernes)
```

Evolució del preu - Cartes Modernes (2017-2021)



Tractament d'outliers univariant

Observem que hi ha molts outliers puntuals (preus = 0 o exageradament elevats). Els eliminarem. Per a no eliminar de manera incorrecta valors, no utilitzaré la mitjana global sinó per “finestres de temps”. Seria incorrecte eliminar una dada que surti de la mitjana global de totes les dades, perquè podria ser una dada normal en un determinat cicle (ex: en una de les bombolles). Un outlier a la finestra temporal del 2022-2023 podria no ser-ho al considerar la mitjana global degut a la influència de les bombolles especulatives de 2025 (a les cartes modernes). És per això que considero finestres de temps i faig el tractament basant-me en aquestes.

Considero finestres temporals de 60 dies (30 dies abans i 30 dies després de la venda).

(després de comprovar aquesta opció, vaig veure que feia eliminacions incorrectes ja que per exemple, en una finestra amb 3 vendes de 10, i una de 5000, s'eliminaven les de 10 degut a que la mitjana tirava més cap a 5000 -efecte emmascament-). És per això que directament passo a l'eliminació manual d'outliers.

```
library(dplyr)

# Filtres manuals per a cartes vintage i modernes
dades_netes <- dades %>%
  filter(
    Price >= 10,
    # vintage
    !(ID_Card == "vin1_charizard_holo_baseset_psa9" & Price > 10000),
    !(ID_Card == "vin1_charizard_holo_baseset_psa9" & Date >= as.Date("2022-01-01") & Price > 4000),
    !(ID_Card == "vin2_blastoise_holo_baseset_psa9" & Date >= as.Date("2022-01-01") & Price > 1500),
```

```

!(ID_Card == "vin2_blastoise_holo_baseset_psa9" & Date >= as.Date("2021-01-01") & Price > 2000),
!(ID_Card == "vin3_venusaur_holo_baseset_psa9" & Date >= as.Date("2023-01-01") & Price > 1000),
!(ID_Card == "vin3_venusaur_holo_baseset_psa9" & Date >= as.Date("2021-01-01") & Price > 1750),
!(ID_Card == "vin3_venusaur_holo_baseset_psa9" & Price > 4000),
!(ID_Card == "vin4_mewtwo_holo_baseset_psa9" & Price > 900),
!(ID_Card == "vin5_pikachu_yellowcheeks_baseset_psa9" & Price > 500),
!(ID_Card == "vin5_pikachu_yellowcheeks_baseset_psa9" & Date >= as.Date("2023-01-01") & Price > 1500),
!(ID_Card == "vin8_darkblastoise_holo_teamrocket_psa9" & Price > 500),
!(ID_Card == "vin9_darkcharizard_holo_teamrocket_psa9" & Price > 5000),
!(ID_Card == "vin10_ancientmew_promomovie_psa9" & Date >= as.Date("2023-01-01") & Price > 300),
# modernes
!(ID_Card == "mod1_mewtwo_gx_sr_shininglegends_psa10" & Date >= as.Date("2025-06-01") & Price < 1800),
!(ID_Card == "mod3_charizard_gx_shiny_hiddenfates_psa10" & Date >= as.Date("2021-01-01") & Price < 3000),
!(ID_Card == "mod4_charizard_v_shiny_championspath_psa10" & Price > 4000),
!(ID_Card == "mod6_charizard_vmax_shiny_shiningfates_psa10" & Price > 3000),
!(ID_Card == "mod6_charizard_vmax_shiny_shiningfates_psa10" & Date >= as.Date("2022-01-01") & Price > 1000),
!(ID_Card == "mod6_charizard_vmax_shiny_shiningfates_psa10" & Date >= as.Date("2023-01-01") & Price > 1000),
!(ID_Card == "mod6_charizard_vmax_shiny_shiningfates_psa10" & Date <= as.Date("2022-06-01") & Price < 1000),
!(ID_Card == "mod7_sylveon_vmax_altart_evolving skies_psa10" & Price < 100),
!(ID_Card == "mod8_umbreon_vmax_altart_evolving skies_psa10" & Date >= as.Date("2025-01-01") & Price < 1000),
!(ID_Card == "mod9_rayquaza_vmax_altart_evolving skies_psa10" & Date >= as.Date("2024-01-01") & Price < 1000),
!(ID_Card == "mod10_gengar_vmax_altart_fusionstrike_psa10" & Date >= as.Date("2024-01-01") & Price < 1000)
)

```

Comprovació de la neteja

```
print(paste("Registres abans:", nrow(dades)))
```

```
## [1] "Registres abans: 20714"
```

```
print(paste("Registres ara:", nrow(dades_netes)))
```

```
## [1] "Registres ara: 20559"
```

```
print(paste("Eliminats (errors o preus nuls):", nrow(dades) - nrow(dades_netes)))
```

```
## [1] "Eliminats (errors o preus nuls): 155"
```

Repetim els gràfics un cop fetes les correccions:

```

# Gràfic cartes vintage corregit
grafic_vintage_corregit <- dades_netes %>%
  filter(Vintage == "Vintage") %>%
  ggplot(aes(x = Date, y = Price)) +
  geom_point(alpha = 0.5, size = 1.5, color = "#00BFC4") +
  geom_line(alpha = 0.7, color = "#00BFC4") +
  facet_wrap(~ ID_Card, scales = "free_y", ncol = 2) +
  scale_x_date(date_labels = "%Y", date_breaks = "1 year") +
  theme_minimal() +
  labs(
    title = "Evolució del preu - Cartes Vintage (1999-2000)",
    x = "Data de venda",

```


```

y = "Preu (USD)"
) +
theme(axis.text.x = element_text(angle = 45, hjust = 1))

print(grafic_vintage_corregit)

```

Evolució del preu - Cartes Vintage (1999-2000)




```

# Gràfic cartes modernes corregit
grafic_modernes_corregit <- dades_netes %>%
  filter(Vintage == "Moderna") %>%
  ggplot(aes(x = Date, y = Price)) +
  geom_point(alpha = 0.5, size = 1.5, color = "#F8766D") +
  geom_line(alpha = 0.7, color = "#F8766D") +
  facet_wrap(~ ID_Card, scales = "free_y", ncol = 2) +
  scale_x_date(date_labels = "%Y", date_breaks = "1 year") +
  theme_minimal() +
  labs(
    title = "Evolució del preu - Cartes Modernes (2017-2021)",
    x = "Data de transacció",
    y = "Preu (USD)"
  ) +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))

print(grafic_modernes_corregit)

```

Evolució del preu - Cartes Modernes (2017-2021)



Amb això hem pogut tractar 155 outliers/errors de pricing a totes les cartes.

```
saveRDS(dades_netes, "C:/Users/joelm/Downloads/TFG/dades_netes.rds")
```